

Ластовичек Дмитрий. АД
БММО
Практическое задание №2

1 Теория

Е-шаг

$$p(d_k|X_k, \theta, A) = \frac{p(X_k|d_k, \theta)p(d_k|A)}{\sum_{d_k} p(X_k|d_k, \theta)p(d_k|A)}$$

М-шаг

$$E_q \log P(X, d|\theta, A) = E_q \sum_k \left[-\frac{1}{2s^2} \sum_{i,j \in face} (X_{ij}^k - F_{i-di,j-dj})^2 - \frac{1}{2s^2} \sum_{i,j \notin face} (X_{ij}^k - B_{i,j})^2 + HW \log \frac{1}{\sqrt{2\pi s^2}} + \log A(d_i^k, d_j^k) \right] \quad (1)$$

A :

Входит только в последнее слагаемое, поэтому

$$\begin{cases} \sum_k \sum_{i,j} \log A_{ij} q_{ij}^k \rightarrow \max_A \\ \sum_{i,j} A_{ij} = 1 \end{cases} \quad (2)$$

Решаем методом Лагранжа:

$$\begin{aligned}
L &= \sum_k \sum_{i,j} \log A_{ij} q_{ij}^k + \lambda (\sum_{i,j} A_{ij} - 1) \\
L'_{A_{ij}} &= \frac{\sum_k q_{ij}^k}{A_{ij}} + \lambda = 0 \\
A_{ij} &= -\frac{\sum_k q_{ij}^k}{\lambda} \\
\sum_{i,j} A_{ij} &= -\frac{\sum_{i,j} \sum_k q_{ij}^k}{\lambda} = 1 \\
A_{ij} &= -\frac{\sum_k q_{ij}^k}{\sum_{i,j} \sum_k q_{ij}^k}
\end{aligned}$$

F :

Входит только в первое слагаемое

$$\begin{aligned}
\sum_k E_q(d_k) \left[-\frac{1}{2s^2} \sum_{i,j \in face} (X_{ij}^k - F_{i-d_i^k, j-d_j^k})^2 \right] &\rightarrow \max_F \\
\sum_k \sum_{d_i, d_j} q_{d_i, d_j}^k \sum_{i,j \in face} (X_{ij}^k - F_{i-d_i, j-d_j})^2 &\rightarrow \min_F \\
\sum_{d_i, d_j} \sum_k q_{d_i, d_j}^k \sum_{i=0}^{h-1} \sum_{j=0}^w (X_{i+d_i, j+d_j}^k - F_{i,j})^2 &\rightarrow \min_F \\
\sum_{i=0}^{h-1} \sum_{j=0}^w \sum_{d_i, d_j} \sum_k q_{d_i, d_j}^k (X_{i+d_i, j+d_j}^k - F_{i,j})^2 &\rightarrow \min_F
\end{aligned}$$

Приравнявая производную к нулю по каждому F_{ij} к нулю получим

$$F_{i,j} = \frac{\sum_{d_i, d_j} \sum_k q_{d_i, d_j}^k X_{i+d_i, j+d_j}^k}{\sum_{d_i, d_j} \sum_k q_{d_i, d_j}^k}$$

B :

Входит только во второе слагаемое:

$$\begin{aligned}
\sum_k E_q(d_k) \left[-\frac{1}{2s^2} \sum_{i,j \notin face} (X_{ij}^k - B_{i,j})^2 \right] &\rightarrow \max_F \\
\sum_k \sum_{d_i, d_j} q_{d_i, d_j}^k \sum_{i,j \notin face} (X_{ij}^k - B_{i,j})^2 &\rightarrow \min_F \\
\sum_{i=0}^{H-1} \sum_{j=0}^{W-1} \sum_{d_i, d_j} \sum_k q_{d_i, d_j}^k (X_{ij}^k - F_{i,j})^2 I(i, j \notin face) &\rightarrow \min_F
\end{aligned}$$

Приравнивая производную к нулю по каждому B_{ij} к нулю получим

$$B_{i,j} = \frac{\sum_{d_i,d_j} \sum_k q_{d_i,d_j}^k X_{i,j}^k I(i,j \notin face)}{\sum_{d_i,d_j} \sum_k q_{d_i,d_j}^k I(i,j \notin face)}$$

s :

Входит в три слагаемых:

$$\begin{aligned} R^k &= \sum_{i=0}^{h-1} \sum_{j=0}^w \sum_{d_i,d_j} \sum_k q_{d_i,d_j}^k (X_{i+d_i,j+d_j}^k - F_{i,j})^2 \\ &+ \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} \sum_{d_i,d_j} \sum_k q_{d_i,d_j}^k (X_{i,j}^k - F_{i,j})^2 I(i,j \notin face) \\ &\sum_k -\frac{R^k}{2s^2} - HWK \log s \rightarrow \max_s \end{aligned}$$

Приравниваем к нулю производную, получим

$$s = \sqrt{\frac{\sum_k R^k}{HWK}}$$

Для MAP-ЕМ просто нужно преобразовать формулы, учитывая, что $q_{d_{ij}}^k$ равна 1 в одной точке

Нижняя оценка L

$$L = \sum_k \sum_{d_i,d_j} [\log p(X_k | d_i, d_j, \theta) + \log A_{d_i,d_j} - \log q_{d_i,d_j}^k] q_{d_i,d_j}^k$$

2 Анализ

2.1 Сгенерированные данные

Сгенерируем тестовые F_{test} , B_{test} . Позиция смайлика выбирается равномерно на фоне для каждого образца. Параметр шума задаем




Рис. 2.1.1: F_{test}




Рис. 2.1.2: B_{test}

Сильно ли влияет начальное приближение на параметры на результаты работы?

Начальное приближение влияет на скорость сходимости и на саму сходимость алгоритма. При плохих начальных приближениях знаменатель в формуле пересчета для B может обратиться в нуль, и метод возвратит NaN. Поэтому в данной работе я использовал начальное приближение основанное на данных X (генерируем начальные F и B как нормальное распределение с в каждой точке i, j как $avg(X_{ij}), std(X_{ij})$)

Стоит ли для данной задачи запускать ЕМ алгоритм из разных начальных приближений?

При выбранных мной начальных приближениях на F и B , описанных выше, алгоритм сходился почти всегда (За исключение, когда в знаменателе для B 0). Поэтому запускать из разных приближений стоит.

2.2 Тестирование на сгенерированных данных

s=10

В данном случае, т.к. s маленький быстро удается определить точное положение смайлика и зануляется знаменатель в B . Поэтому приходится делать несколько запусков.

Число образцов = 500. L=-1118552.85311.




Рис. 2.2.1: $X_{test}example$




Рис. 2.2.2: $F_{test}500samples$




Рис. 2.2.3: $B_{test}500samples$

Число образцов = 100. В данном случае образцов мало, и может быть ситуация что смайлик всегда перекрывает середину изображения, поэтому фон в центре невоз-

можно определить и запуски часто не сходятся, а сходятся лишь для не совсем верного F (который "якобы" не перекрывает центр).




Рис. 2.2.4: $F_{test} 500samples$




Рис. 2.2.5: $B_{test} 500samples$

Далее для фиксированного числа образцов (500) буду увеличивать шум

$s=50$. $L=-1601106.65413$




Рис. 2.2.6: $X_{test}example$




Рис. 2.2.7: F_{test}




Рис. 2.2.8: B_{test}

s=100. L=-1809391.78374




Рис. 2.2.9: $X_{test}example$




Рис. 2.2.10: F_{test}




Рис. 2.2.11: B_{test}

s=150. L=-1930956.92011




Рис. 2.2.12: $X_{testexample}$




Рис. 2.2.13: F_{test}




Рис. 2.2.14: B_{test}

s=200. L=-2016634.89901




Рис. 2.2.15: $X_{testexample}$




Рис. 2.2.16: F_{test}




Рис. 2.2.17: B_{test}

s=300. L=-2138216.35902




Рис. 2.2.18: $X_{test}example$




Рис. 2.2.19: F_{test}




Рис. 2.2.20: B_{test}

s=400. L=-2224396.74142




Рис. 2.2.21: $X_{test}example$




Рис. 2.2.22: F_{test}




Рис. 2.2.23: B_{test}

s=600. L=-2224396.74142

Здесь уже объекты не различимы. Заметим что правдоподобие все время уменьшалось с увеличением s , что очевидно.




Рис. 2.2.24: $X_{test}example$




Рис. 2.2.25: F_{test}




Рис. 2.2.26: B_{test}

2.3 EM vs MAP-EM

$$L_{MAP-EM} = -807325.715869$$

$L_{EM} = -806741.622603$ Получаем, что MAP-EM работает несколько хуже, что очевидно, учитывая, что мы сделали приближенное упрощение модели.




Рис. 2.3.1: f_{em}




Рис. 2.3.2: b_{em}




Рис. 2.3.3: f_{map-em}




Рис. 2.3.4: b_{map-em}

2.4 Преступник

На всей выборке получаем:




Рис. 2.4.1: F




Рис. 2.4.2: B

На выборке 200 образцов получаем:




Рис. 2.4.3: F




Рис. 2.4.4: B

2.5 Модификации

Единственное, что я сделал для ускорения программы - немного оптимизировал вычисление lpx_d и s (изначально вычисление lpx_d и s занимало порядка 350 секунд на 1 итерации, после оптимизации кода - 130 секунд) Суть оптимизации заключается в том, что мы считаем отклонение X от B (в области вне $face$) не каждый раз, а пересчитываем по сравнению с предыдущим шагом - например dj сместилось вправо и мы пересчитываем отклонение лишь по изменению покрываемой области $face$ на данном шаге.

Еще можно распараллелить все циклы по образцам и позиции начала преступника.